Предсказание продаж по данным от 1С (kaggle)

Антон Серков, 2020 г.

План презентации

- Описание проблемы
- Ознакомление с данными
- Обзорный анализ данных (EDA)
- Выделение признаков и ML модель
- Дальнейшие шаги

Описание проблемы

Бэкграунд

- За счет того, что компания 1С является одним из крупным поставщиков софта для ритейла, они имеют доступ к большому количеству транзакционных данных.
- На их основе предполагается предсказать будущие объемы продаж, что, возможно, позволит ритейлерам скорректировать логистику и ценообразование.

Описание проблемы

Кейс

- Имеются транзакционные данные по 22170 товарам и 60 магазинам за 34 месяца (2013-2015 годы) (тренировочная выборка)
- Необходимо предсказать продажи определенных товаров (5100 наименований) в заданных магазинах (42 точки) за 35-ый месяц (тестовая выборка)
- Тестовая выборка составлена таким образом, что в ней встречаются **все** возможные комбинации товар-магазин для определенного списка магазинов и товаров. Некоторые товары (около 360 штук) отсутствуют в тренировочной выборке

Ознакомление с данными

Имеющиеся данные состоят из:

- sales_train.csv - Тренировочная выборка. Транзакционные данные с января 2013 по октябрь 2015 (около 3 млн строк);
- test.csv - Тестовая выборка. Необходимо предсказать объем продаж по заданным парам товар-магазин за ноябрь 2015;
- items.csv - дополнительная информация о товарах (название и категория);
- item_categories.csv - дополнительная информация о категориях товаров (название категории);
- shops.csv - дополнительные данные по магазинам (название/город).

Обзорный анализ данных (EDA)

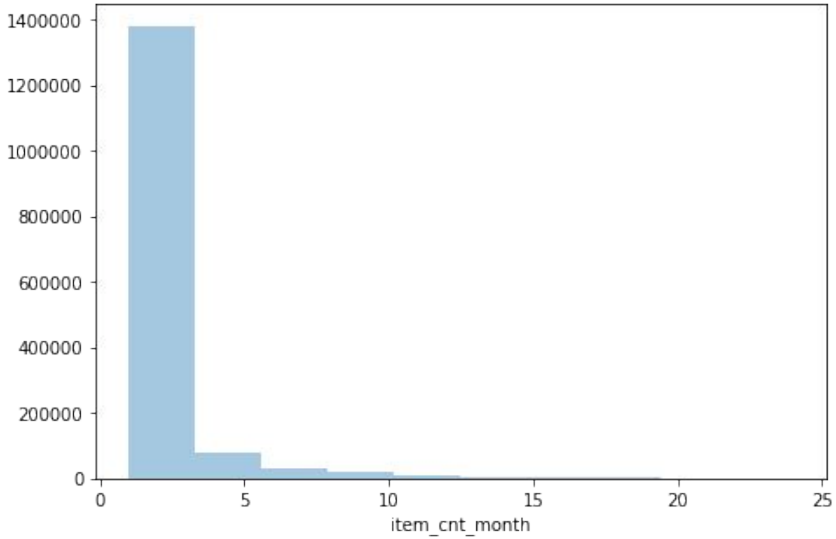

Распределение целевой переменной (объем продаж за месяц)

Согласно тренировочной выборке, большинство (около 70%) продаж заданных пар товар-магазин составляют продажу только одного товара за месяц. В 95% случаев эта величина не превышает 5.

Обзорный анализ данных (EDA)

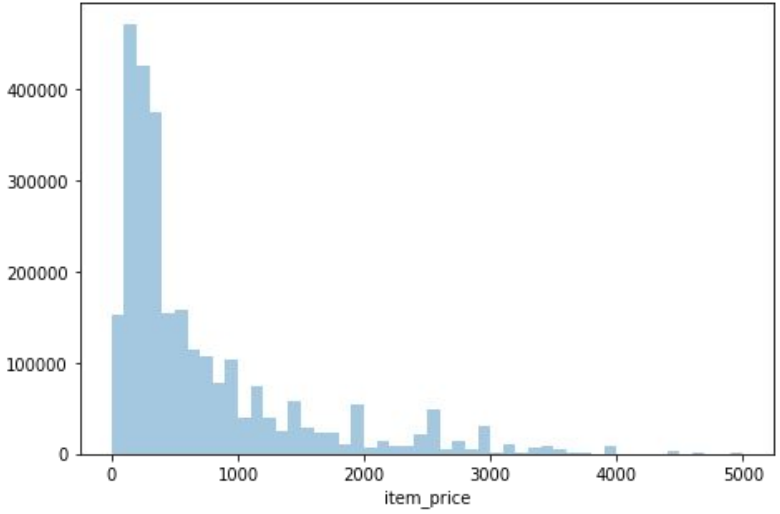

Распределение транзакций по цене товара.

Распределение товаров по ценам имеет ярко выраженный максимум в области 300 руб.
Около 75% процентов всех продаж составляют продажи товаров ценой от 100 до 1000 руб.

Обзорный анализ данных (EDA)

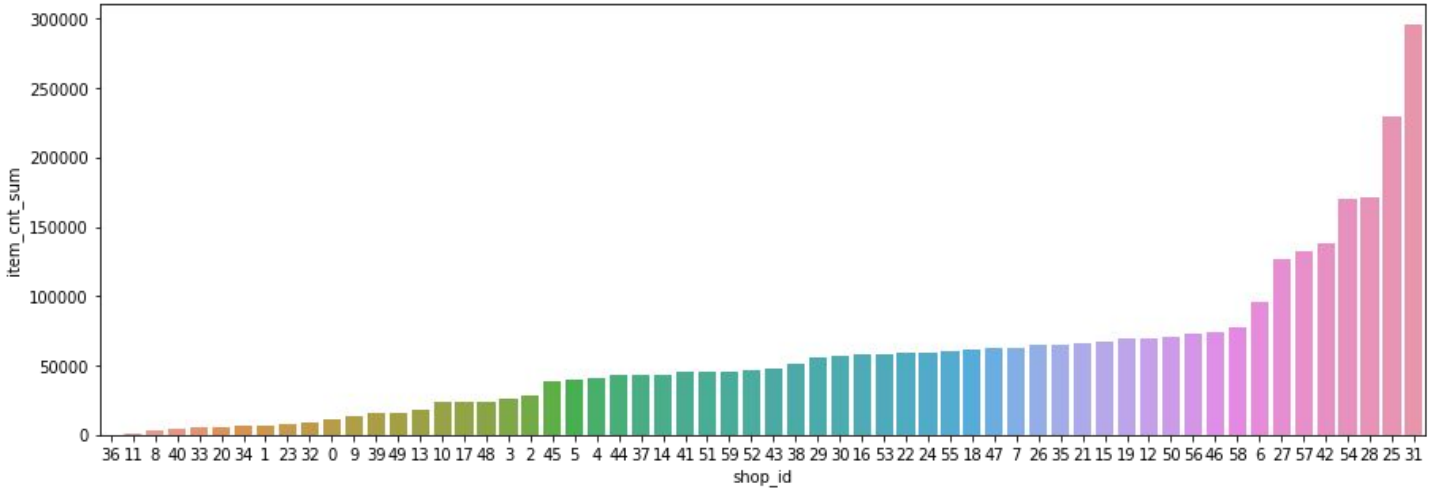

Распределение целевой переменной по магазинам

Согласно тренировочной выборке, top 5 магазинов по объемам продаж - крупные торговые центры в Москве или СПБ

Обзорный анализ данных (EDA)

Основные категории по объемам продаж: кино и игры (PC/приставки)

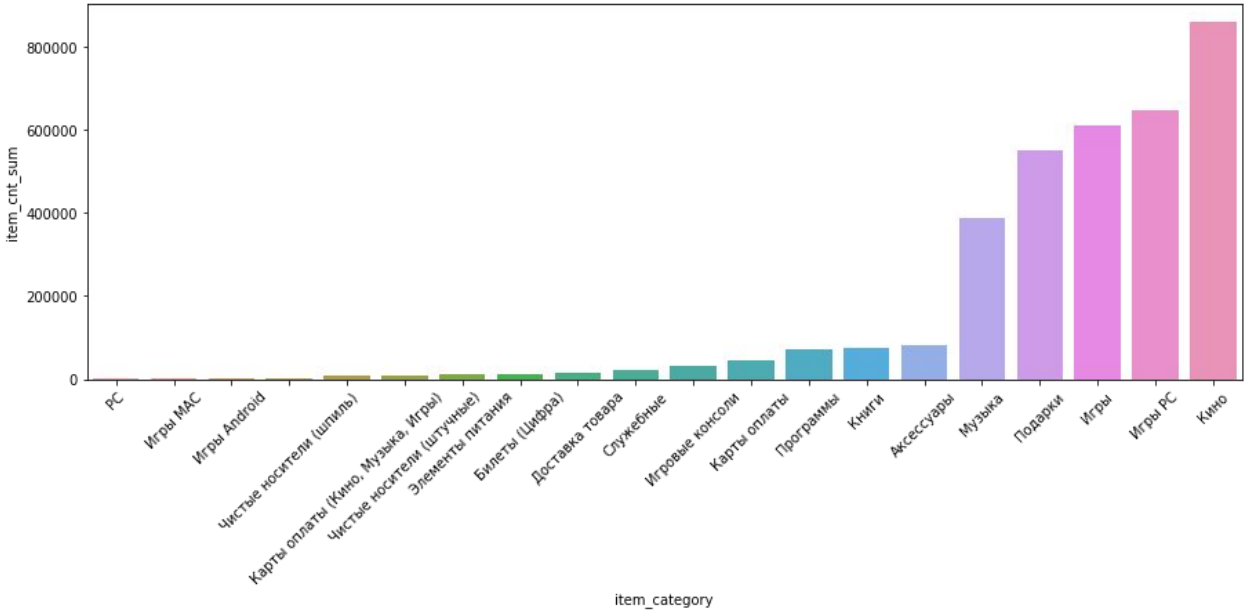

Распределение целевой переменной по категориям

Обзорный анализ данных (EDA)

Сезонность:

Суммарный объем продаж за месяц имеет **ярко выраженную сезонность** и **отрицательный тренд.**

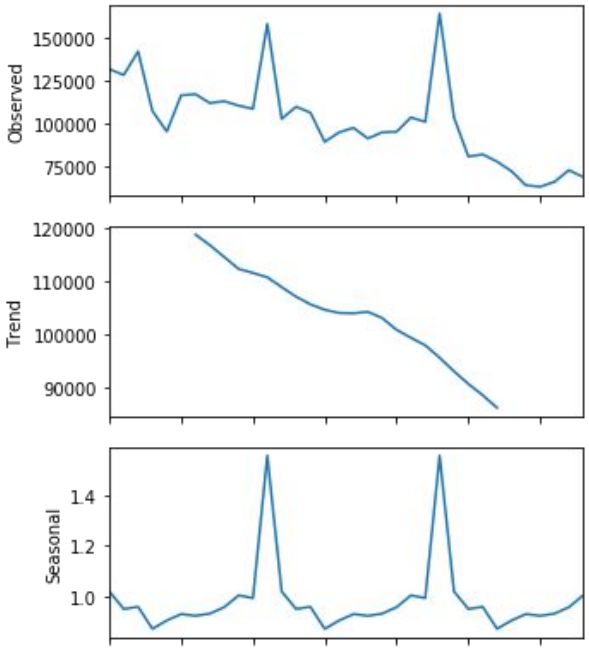

Построение модели

- В качестве регрессора использовался популярный пакет от компании Microsoft - LightGBM. Его преимуществами в сравнении с остальными являются быстрота обучения и оптимальное использования оперативной памяти.
- Основным признаком для baseline-модели были **продажи данного товара в данном магазине за предыдущий месяц**, вспомогательные признаки - **категория и подкатегория товара, город и тип магазина**.
- Для baseline-модели было достигнуто следующее значение метрики:

  Root of Mean Squared Error (RMSE) = 1.0

Выделение признаков

Для улучшения качества модели были выделены дополнительные признаки. Вычисление наиболее значимых из них основано на **усреднении целевой переменной за предыдущие месяцы по различным параметрам**:

- По всем магазинам и товарам (фиксированный месяц);
- По всем магазинам (фиксированные товар и месяц);
- По всем товарам (фиксированные магазин и месяц);
- По фиксированной категории товара и месяцу.

Выделение признаков

Вспомогательными признаками, использованными при построении модели, являются:

- **Количество месяцев**, прошедших с момента первой продажи данного товара в данном магазине;
- **Средняя цена товара** в предыдущие месяцы и ее отклонение от среднего значения;
- **Число дней в месяце**, когда в данном магазине произошли продажи данного товара и **среднее количество проданных единиц** товара за день;

Выделение признаков

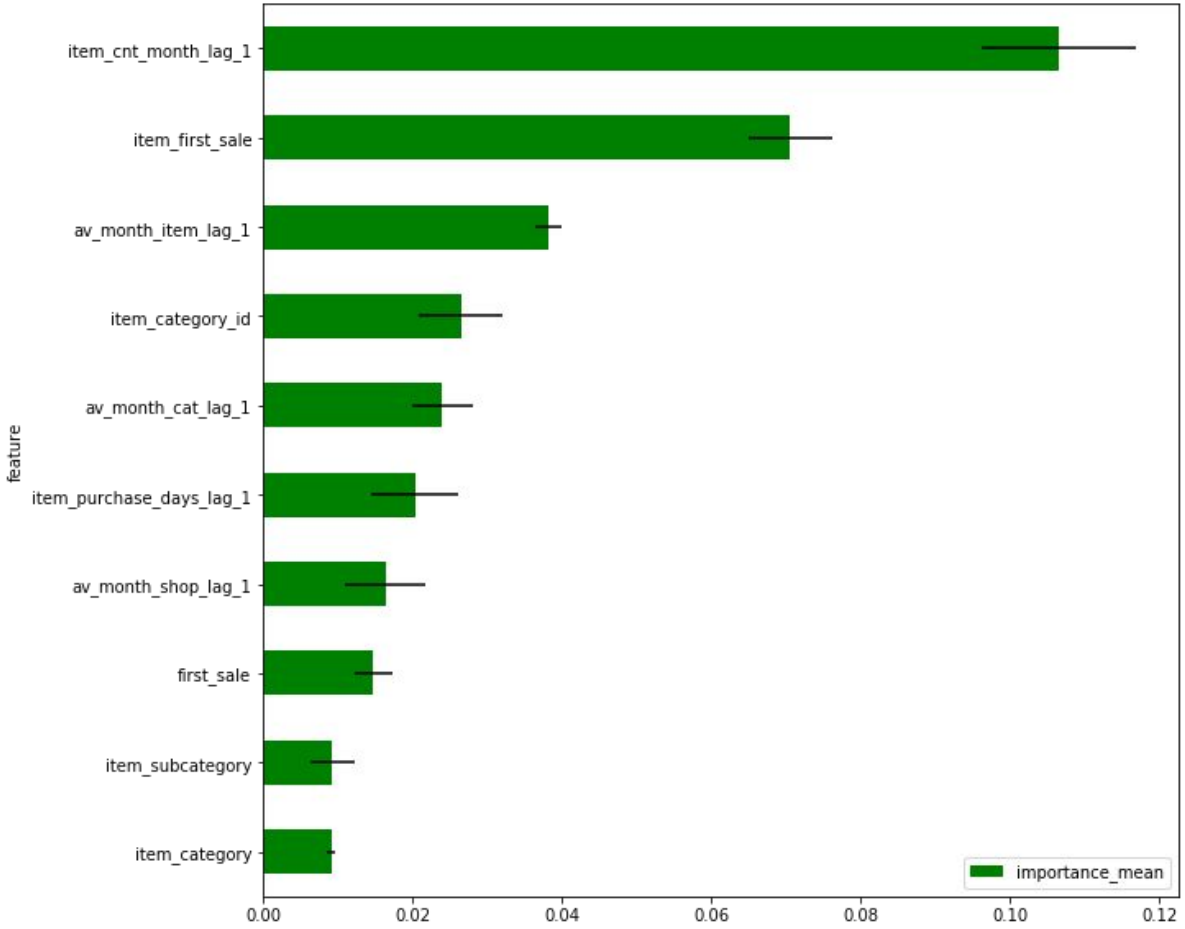

Наличие дополнительных признаков позволило улучшить значение метрики на 10% и достичь значения:

RMSE = 0.896

Выделение признаков

Основные признаки, повлиявшими на итоговую метрику, - **значения целевой переменной** за прошлые месяцы, усредненные по различным категориям.

Помимо этого, **количество месяцев, прошедшее с момента появления товара в продаже** в данном магазине.

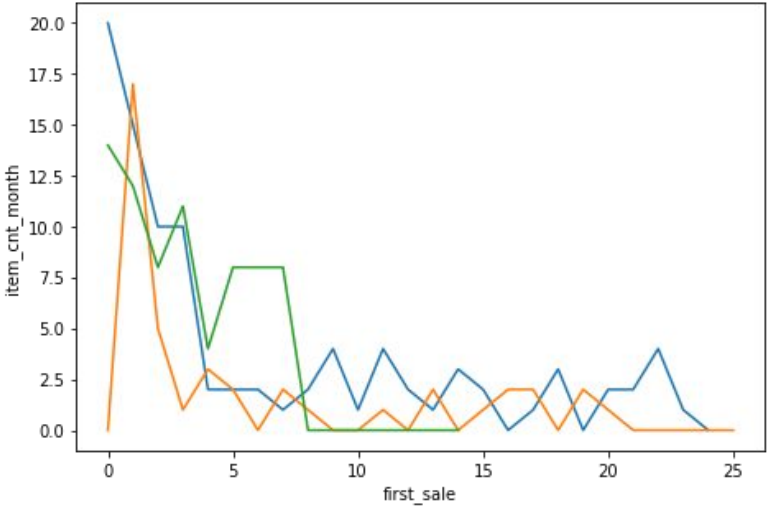

Зависимость целевой переменной от количества месяцев, прошедших с момента появления товара в продаже

Дальнейшие шаги

1. Минимизация ошибки для “новых” наименований:
   a. Оценка цены товара перед началом его продаж;
   b. Анализ совместно покупаемых товаров (совместный анализ корзины, поиск корреляций в продажах различных товаров);
2. Более подробный анализ сезонных факторов: учет категорий товаров;
3. Совместная работа с маркетологами: оценка влияния акций/скидок на товары;
4.

Спасибо за внимание!